TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP HỒ CHÍ MINH
NGÀNH CÔNG NGHỆ THÔNG TIN

BÁO CÁO TIẾN ĐỘ OCR VÀ MÔ HÌNH TRÍCH XUẤT CV

Đề tài KLCN029

Nghiên cứu hệ thống hỗ trợ đánh giá và cải thiện CV sử dụng mô hình ngôn ngữ lớn

Giảng viên hướng dẫn	Huỳnh Thị Cẩm Dung
Sinh viên thực hiện	Nguyễn Hữu Lộc 2001230468 14DHTH01 Dương Chí Khải 2001230364 14DHTH01 Lê Tâm Đắc 2001230169 14DHTH03
Thời điểm báo cáo	Ngày 29 tháng 09 năm 2026
Mục đích	Báo cáo kết quả pilot và xin ý kiến trước khi chạy baseline end to end trên 80 CV thật

TP Hồ Chí Minh 2026

Tóm tắt kết quả và nội dung xin hướng dẫn

Nhóm đã hoàn thành ba phần nền tảng của nhánh Resume Parsing: thiết kế CVSchema 2.0 và chính sách kỹ năng; huấn luyện Qwen3 4B bằng QLoRA; xây dựng Parser v1 và đánh giá trên validation cùng test khóa. Đồng thời, nhóm đã kiểm tra nhánh OCR trên CV thật để lựa chọn engine cho tiếng Anh và tiếng Việt.

Kết quả test khóa trên 75 CV tổng hợp tiếng Anh cho thấy Qwen sau QLoRA đạt Micro F1 99,52%, so với 87,98% của Qwen gốc. Toàn bộ 75 đầu ra của adapter được Parser v1 khôi phục và vượt CVSchema 2.0. Tuy nhiên, raw output của adapter có wrapper suy luận nên strict JSON bằng 0%; Parser v1 là thành phần bắt buộc trong pipeline.

Pilot OCR tiếng Việt cho thấy PaddleOCR Latin không giữ được dấu tốt. Phương án lai gồm PaddleOCR phát hiện vùng chữ, VietOCR Seq2Seq nhận dạng nội dung tiếng Việt và PaddleOCR nhận dạng lại dòng liên hệ đạt Token F1 94,66%, recall từ có dấu 96,57% và 13/15 định danh đúng tuyệt đối.

Nhóm đề nghị giảng viên xem xét kiến trúc OCR theo ngôn ngữ, phạm vi dữ liệu cần bổ sung và kế hoạch đánh giá end to end trước khi nhóm chạy baseline trên toàn bộ 80 CV thật.

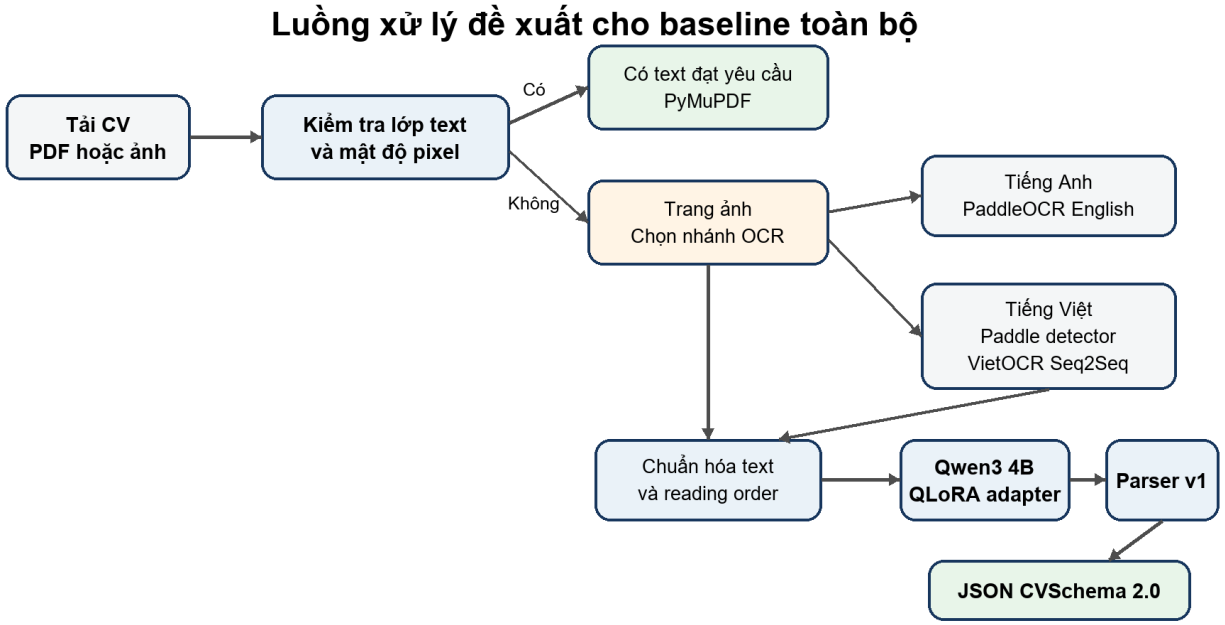
Kết luận hiện tại

- PDF có lớp văn bản: dùng PyMuPDF làm nhánh chính.
- CV scan tiếng Anh: dùng PaddleOCR English và gắn cờ review cho lỗi ký tự hoặc thứ tự hai cột.
- CV scan tiếng Việt: dùng PaddleOCR detector, VietOCR vgg_seq2seq và fallback PaddleOCR cho email, URL, số điện thoại.
- Trích xuất cấu trúc: dùng Qwen3 4B với adapter QLoRA, sau đó qua Parser v1 và kiểm tra CVSchema 2.0.
- Chưa kết luận chất lượng end to end trên 80 CV thật vì chưa chạy toàn bộ pipeline và chưa có gold JSON khóa cho tập đánh giá thực tế.

Phạm vi báo cáo

Báo cáo tập trung vào OCR và trích xuất thông tin CV. Các phần chấm điểm CV, so khớp CV với Job Description, RAG và sinh gợi ý cải thiện chưa nằm trong đợt thực nghiệm này.

Kiến trúc pipeline đề xuất



Hình 1 Luồng xử lý dự kiến cho baseline end to end

Nút chọn ngôn ngữ trên giao diện dự kiến gồm Tự động, Tiếng Việt và Tiếng Anh. Lựa chọn ngôn ngữ chỉ điều khiển nhánh OCR khi trang không có lớp text đủ dùng. Với PDF có lớp text, pipeline giữ dữ liệu gốc từ PyMuPDF nhằm tránh lỗi OCR không cần thiết.

Dữ liệu và hợp đồng đầu ra

Bộ dữ liệu huấn luyện

Nhóm sử dụng bộ dữ liệu sukhrobnurali resume parsing vision, revision 3c254be39d45f69c6e20bfb325b4e6ccb3b5e393, giấy phép CC BY 4.0. Dữ liệu được chuyển sang CVSchema 2.0 và khóa theo ba tập độc lập.

Tập	Số mẫu	Mục đích	Quy tắc sử dụng
Train	850	Huấn luyện QLoRA	Được dùng để cập nhật adapter
Validation	75	Chọn cấu hình và đóng băng parser	Không dùng cập nhật trọng số
Test khóa	75	Đánh giá cuối	Chỉ mở sau khi đóng băng parser và metric

Nguồn số liệu: *training/data/resume_parsing_vision_cvschema_v2/manifest.json và conversion_report.json*

Cả validation và test khóa đều là CV tổng hợp tiếng Anh. Ảnh không được tải về; trường resume_text là đầu vào mô hình. Tên, email, số điện thoại và ngày sinh tổng hợp đã được che trong văn bản nguồn. Vì vậy kết quả mô hình chỉ chứng minh năng lực ánh xạ text sạch sang schema, chưa chứng minh OCR hoặc khả năng tổng quát sang CV tiếng Việt thực tế.

Bộ 80 CV thật của đề tài

Chỉ số	Kết quả
CV tiếng Anh	60
CV tiếng Việt	20
Tổng số trang	110
Nội dung độc nhất	77
Cặp tệp trùng SHA 256	3
Tệp lỗi hoặc có mật khẩu	0

Rà soát lớp text cho thấy toàn bộ 20 CV tiếng Việt hiện có đều đọc được bằng PyMuPDF. Trong tám trang tiếng Anh từng bị đánh dấu ít text, chỉ EN047 có đủ nội dung ảnh để cần OCR; bảy trang còn lại gần trắng hoặc chỉ có phần tử trang trí.

CVSchema 2.0 và chính sách kỹ năng

Đầu ra gồm thông tin cá nhân, tóm tắt, kỹ năng, kinh nghiệm, dự án, học vấn, chứng chỉ, hoạt động và thành tích. Theo quyết định đã được nhóm rà soát ngày 23 tháng 09 năm 2026, chỉ Communication thuộc soft skill; các kỹ năng nguồn còn lại thuộc hard skill. Parser kiểm tra không cho một kỹ năng xuất hiện đồng thời ở hai nhóm.

Thử nghiệm OCR

Mục tiêu và thiết lập

Pilot OCR dùng năm trang đầu của VI001, VI006, VI013, VI018 và VI020, raster ở 200 DPI. Lớp text PDF được dùng làm tham chiếu. Cùng polygon phát hiện từ PP OCRv5 mobile detector được tái sử dụng để so sánh recognizer, giúp cô lập ảnh hưởng của phần nhận dạng ký tự.

Các chỉ số gồm Character Error Rate và Word Error Rate có xét thứ tự, Token F1 dạng multiset, recall token có dấu, recall thuật ngữ kỹ thuật và tỷ lệ email, URL, số điện thoại khớp tuyệt đối. Token F1 và recall từ có dấu từ 90% trở lên được dùng làm ngưỡng pilot cho recognizer.

Kết quả so sánh

Phương án	Token F1	Recall có dấu	Recall kỹ thuật	Định danh đúng	Giây trên trang
PaddleOCR v5 Latin	55,81%	39,60%	95,95%	13/15	34,84
VietOCR Seq2Seq	94,15%	96,57%	93,58%	7/15	7,97*
VietOCR Transformer	96,38%	99,01%	91,75%	6/15	38,21*
Hybrid Seq2Seq	94,66%	96,57%	93,58%	13/15	7,97*
Hybrid Transformer	96,82%	99,01%	91,75%	13/15	38,21*

Nguồn số liệu: *experiments/ocr/vietocr_hybrid_pilot_v1/comparison_summary.json. Dấu sao là thời gian recognition only; PaddleOCR gồm detector và recognizer nên không so sánh trực tiếp thời gian end to end.*

Phân tích kết quả

PaddleOCR Latin có confidence trung bình cao nhưng thiếu nhiều ký tự tiếng Việt dựng sẵn, dẫn đến mất dấu trên diện rộng. VietOCR cải thiện rõ rệt nội dung tiếng Việt. Transformer cao hơn Seq2Seq 2,23 điểm Token F1 nhưng chậm hơn khoảng 4,8 lần trên CPU, vì vậy Seq2Seq phù hợp hơn với baseline có giới hạn tài nguyên.

VietOCR thường thay ký tự @ bằng O hoặc 0 và có thể nhầm chữ với số trong URL. Bộ chọn lai dùng VietOCR cho nội dung tiếng Việt và kết quả PaddleOCR cho các dòng liên hệ, tăng định danh đúng tuyệt đối từ 7/15 lên 13/15 đối với Seq2Seq. Hai lỗi còn lại nằm ở URL của VI020.

Quyết định OCR tạm thời

1. Trích text bằng PyMuPDF trước khi xét OCR.
2. Chỉ OCR khi trang có dưới 80 ký tự native và tỷ lệ pixel tối từ 0,02 trở lên; cần cài đặt và kiểm thử rule này trước batch toàn bộ.
3. Dùng PaddleOCR English cho CV scan tiếng Anh.
4. Dùng Paddle detector, VietOCR vgg_seq2seq và contact fallback cho CV scan tiếng Việt.
5. Gắn cờ review khi email, URL hoặc số điện thoại không vượt validation định dạng hoặc có confidence thấp.

Giới hạn OCR

- Năm trang tiếng Việt được raster từ PDF sạch, chưa đại diện ảnh chụp nghiêng, nhiễu hoặc scan chất lượng thấp.
- Benchmark recognizer tái sử dụng polygon detector, nên chưa có thời gian end to end cho nhánh hybrid.
- Thứ tự đọc CV nhiều cột vẫn cần module layout riêng và kiểm tra trực quan.

Huấn luyện mô hình trích xuất

Cấu hình QLoRA

Thành phần	Cấu hình
Mô hình nền	Qwen Qwen3 4B Instruct 2507
Phương pháp	QLoRA với NF4 và double quantization
LoRA	Rank 16 Alpha 32 Dropout 0,05 toàn bộ linear
Dữ liệu	850 train 75 validation
Batch hiệu dụng	8
Số epoch và bước	1 epoch 107 bước
Thời gian Trainer	2.292,47 giây khoảng 38 phút 12 giây
Peak GPU	8,184 GiB allocated 12,447 GiB reserved
Tham số LoRA	33.030.144 tham số FP32

Nguồn số liệu: *training/audits/final_adapter-full_1.audit.md*

Adapter ZIP đã qua kiểm tra CRC, manifest, kích thước và SHA 256. Artifact chứa đủ trọng số, tokenizer, run config, metrics và Trainer state. Cấu hình checkpoint trên Google Drive cho phép tiếp tục huấn luyện khi Colab Free bị ngắt.

Dấu hiệu hội tụ

Bước	Eval loss	Token accuracy
40	0,015352	0,995554
80	0,011234	0,999367
107	0,010912	0,999482

Eval loss giảm ở cả ba mốc và log không có NaN hoặc Inf. Đây là teacher forced metrics, dùng để kiểm tra quá trình tối ưu; chất lượng sinh tự do được đánh giá riêng bằng validation và test khóa.

Parser v1

Parser v1 được đóng băng sau validation. Parser chỉ loại bỏ wrapper đã khai báo gồm khối think hoàn chỉnh, thẻ đóng tool call ở đầu và JSON fence bao toàn bộ phản hồi; không sửa JSON thiếu hoặc output bị cắt. Thiết kế này tách năng lực mô hình khỏi cơ chế phục hồi định dạng.

Đánh giá mô hình trích xuất

Kết quả validation

Chỉ số	Qwen gốc	Qwen QLoRA	Chênh lệch
Recoverable JSON	97,33%	100,00%	+2,67 điểm %
Schema hợp lệ	97,33%	100,00%	+2,67 điểm %
Chính sách kỹ năng	46,67%	98,67%	+52,00 điểm %
Exact full JSON	0,00%	81,33%	+81,33 điểm %
Micro F1	88,06%	99,60%	+11,53 điểm %
Macro F1	77,62%	98,77%	+21,15 điểm %

Nguồn số liệu: *training/evaluation/results/validation_base_vs_adapter_v1/comparison_report.md*

Kết quả test khóa

Chỉ số	Qwen gốc	Qwen QLoRA	Chênh lệch
Recoverable JSON	97,33%	100,00%	+2,67 điểm %
Schema hợp lệ	97,33%	100,00%	+2,67 điểm %
Chính sách kỹ năng	53,33%	100,00%	+46,67 điểm %
Exact full JSON	1,33%	76,00%	+74,67 điểm %
Micro precision	88,39%	99,55%	+11,16 điểm %
Micro recall	87,58%	99,49%	+11,91 điểm %
Micro F1	87,98%	99,52%	+11,54 điểm %
Macro F1	78,58%	98,85%	+20,27 điểm %
Chạm giới hạn token	2/75	0/75	Giảm 2 mẫu

Nguồn số liệu: *training/evaluation/results/locked_test_base_vs_adapter_v1/report_ready_results_vi.md*

Micro F1 của adapter trên test chỉ thấp hơn validation 0,08 điểm phần trăm. Điều này cho thấy chất lượng theo trường ổn định trên phần dữ liệu chưa dùng để chọn cấu hình. Exact full JSON giảm 5,33 điểm phần trăm vì chỉ một trường sai cũng làm cả mẫu bị tính sai.

Lỗi còn lại trên test khóa

Trường	Mẫu có sai khác	F1 test	Nhận xét
projects role	13	87,58%	Vai trò thường phải suy ra từ mô tả
skills hard skills	4	99,59%	Một số khác biệt chuẩn hóa danh sách
experience job title	1	99,82%	Sai khác đơn lẻ

Trường	Mẫu có sai khác	F1 test	Nhận xét
certifications	1	95,74%	Support nhỏ nên nhạy với một lỗi

Vai trò bắt buộc của Parser

Strict JSON của raw adapter bằng 0% vì 70 mẫu có wrapper think và 5 mẫu có thẻ đóng tool call ở đầu. Parser v1 khôi phục đủ 75 mẫu và toàn bộ đầu ra sau parser hợp lệ theo schema. Pipeline triển khai phải giữ bước parser; kết quả raw không được chuyển thẳng cho thành phần tiêu thụ JSON.

Những kết luận đã có và khoảng trống

Nội dung	Trạng thái	Bằng chứng hoặc khoảng trống
QLoRA cải thiện extraction	Đã chứng minh	Test khóa tăng Micro F1 từ 87,98% lên 99,52%
Tuân thủ CVSchema 2.0	Đã chứng minh	75/75 test hợp lệ sau Parser v1
OCR tiếng Việt trên bản raster sạch	Đã thử nghiệm	Hybrid Seq2Seq đạt Token F1 94,66%
OCR scan tiếng Anh	Pilot một CV	EN047 đọc được nội dung nhưng còn lỗi ký tự và reading order
OCR ảnh chụp hoặc scan xấu tiếng Việt	Chưa chứng minh	Chưa có tập mẫu đại diện
Extraction trên CV tiếng Việt thật	Chưa chứng minh	Chưa có gold JSON khóa và chưa chạy toàn bộ
Pipeline end to end trên 80 CV	Chưa chạy	Cần hoàn thiện router và log thực nghiệm

Kế hoạch chạy baseline toàn bộ

1. Đóng băng phiên bản code, schema, parser, adapter và cấu hình OCR; lưu hash cho từng artifact.
2. Cài đặt router theo lớp text và mật độ pixel; thêm lựa chọn Tự động, Tiếng Việt và Tiếng Anh trên giao diện.
3. Chạy bước trích text hoặc OCR trên 80 CV, lưu engine, thời gian, số dòng, confidence và cờ review theo từng trang.
4. Đưa text đã chuẩn hóa vào Qwen QLoRA bằng greedy decoding; lưu raw output trước parser.
5. Áp dụng Parser v1, kiểm tra CVSchema 2.0 và chính sách kỹ năng; lưu lý do lỗi thay vì sửa ngầm.
6. Báo cáo riêng ba nhóm: English native text, Vietnamese native text và OCR fallback.
7. Sau khi có gold JSON, tính Precision, Recall, F1 theo trường, Exact full JSON và tỷ lệ schema hợp lệ; phân loại lỗi OCR, layout, extraction và parser.

Artifact cần lưu sau lượt chạy

Artifact	Nội dung
run manifest	Phiên bản model, adapter, parser, schema, OCR và hash dữ liệu
page routing log	Native chars, dark pixel ratio, ngôn ngữ, engine, runtime, cờ review

Artifact	Nội dung
raw predictions	Đầu ra Qwen trước parser
parsed predictions	JSON sau Parser v1 và kết quả schema validation
metrics	Tổng hợp toàn bộ, theo ngôn ngữ và theo nhánh OCR
error analysis	Danh sách mẫu lỗi và nguyên nhân được rà soát

Nội dung xin ý kiến giảng viên

Trước khi chạy baseline toàn bộ, nhóm kính đề nghị giảng viên góp ý và xác nhận các nội dung sau:

1. Kiến trúc hai nhánh OCR theo ngôn ngữ có phù hợp không, hay nhóm cần thống nhất một OCR duy nhất để dễ so sánh?
2. Giảng viên có đồng ý dùng chế độ Tự động làm mặc định và cho người dùng chọn Tiếng Việt hoặc Tiếng Anh khi tải CV không?
3. Phương án PaddleOCR detector, VietOCR Seq2Seq và fallback dòng liên hệ có được xem là baseline chính cho CV scan tiếng Việt không?
4. Nhóm có cần bổ sung một tập CV tiếng Việt scan hoặc ảnh chụp thật trước khi khóa kết luận OCR không? Nếu có, số lượng tối thiểu nên là bao nhiêu trang?
5. Có thể dùng 20 CV thật trong test khóa để gán gold JSON không, và có cần hai người gán nhãn độc lập rồi đối chiếu bất đồng không?
6. Đối với đóng góp huấn luyện, việc fine tune Qwen bằng QLoRA và so sánh với Qwen gốc đã đủ yêu cầu chưa, hay cần thêm một cấu hình huấn luyện hoặc một model đối chứng?
7. Việc giữ Parser v1 để loại wrapper định dạng có phù hợp với cách đánh giá không, khi raw output của adapter không đạt strict JSON?
8. Giảng viên có đồng ý báo cáo tách ba tầng OCR, extraction trên text sạch và end to end để tránh quy lỗi sai tầng không?
9. Trường projects role hiện là lỗi chính còn lại. Nhóm nên giữ trường này, đổi thành nullable khi CV không nêu rõ hay bổ sung hướng dẫn suy luận trong dữ liệu huấn luyện?
10. Nhóm có thể bắt đầu chạy baseline toàn bộ 80 CV sau khi hoàn thiện router và đóng băng run manifest không?

Đề xuất của nhóm

Nhóm đề xuất giữ kiến trúc hiện tại và thực hiện thêm một kiểm tra nhỏ trên CV tiếng Việt scan thực tế trước khi đóng băng OCR. Sau khi được giảng viên thống nhất phạm vi đánh giá, nhóm sẽ chạy baseline trên 80 CV và báo cáo tách biệt lỗi OCR, lỗi bố cục, lỗi trích xuất ngữ nghĩa và lỗi định dạng đầu ra.

Trong báo cáo khóa luận, kết quả 99,52% Micro F1 sẽ được mô tả đúng phạm vi là text sạch từ dữ liệu tổng hợp tiếng Anh. Chất lượng trên CV thật chỉ được công bố sau lượt chạy end to end và đối chiếu với nhãn gold.